

Rekonstrukcja obrazów tomografii komputerowej za pomocą sieci neuronowej głębokiej na podstawie syntetycznego zbioru uczącego

Autor: **Kamil Cisek**

Promotor: prof. dr hab. inż. Waldemar Smolik, Instytut
Radioelektroniki i Technik Multimedialnych

Seminarium Dyplomowe Inżynierskie

20 października 2025

- 1 Tomografia komputerowa - wstęp
- 2 Cel pracy
- 3 Zbiór uczący
- 4 Metody rekonstrukcji obrazów
- 5 Trening sieci neuronowej
- 6 Dotychczasowe wyniki prac
- 7 Plan bieżącego semestru

Tomografia komputerowa (rentgenowska)

- **Tomografia** - technika obrazowania przekrojów obiektów na podstawie pomiarów dokonywanych z zewnątrz.
- Pomiar polega na rejestracji osłabienia promieniowania X przez obiekt.
- Na podstawie danych (tzw. projekcji) rekonstruuje się obraz przekroju numerycznie.



Rysunek: Tomograf komputerowy

Problem prosty

Jeśli znamy transformację R , to dla przyjętego obiektu f możemy wyznaczyć jego projekcje:

$$g = R\{f\}$$

gdzie $f(x, y)$ - obiekt, $g(r, \theta)$ - projekcje.



Problem odwrotny

Znając projekcje g , szukamy obrazu f :

$$f = R^{-1}\{g\}$$

Problem prosty i odwrotny

- Aby zrekonstruować przekrój obiektu na podstawie pomiarów tomograficznych należy dokonać transformacji odwrotnej.
- Uwzględniając wszystkie efekty fizyczne (utwardzanie wiązki) mamy do czynienia z transformacją nieliniową.



Rysunek: Obiekt (f) i projekcje (g)

- Generacja syntetycznego zbioru uczącego.
- Zastosowanie uczenia maszynowego (z nadzorem) do rozwiązania problemu odwrotnego w tomografii komputerowej.
- Określenie minimalnego rozmiaru zbioru uczącego potrzebnego do osiągnięcia dobrych wyników.
- Sprawdzenie, czy możliwe jest nauczanie transformacji odwrotnej przy użyciu naturalnych obrazów (nie tomograficznych).
- Opcjonalnie, porównanie wyników z klasycznymi metodami rekonstrukcji.

- Generacja syntetycznego zbioru uczącego.
- Zastosowanie uczenia maszynowego (z nadzorem) do rozwiązania problemu odwrotnego w tomografii komputerowej.
- Określenie minimalnego rozmiaru zbioru uczącego potrzebnego do osiągnięcia dobrych wyników.
- Sprawdzenie, czy możliwe jest nauczanie transformacji odwrotnej przy użyciu naturalnych obrazów (nie tomograficznych).
- Opcjonalnie, porównanie wyników z klasycznymi metodami rekonstrukcji.

- Generacja syntetycznego zbioru uczącego.
- Zastosowanie uczenia maszynowego (z nadzorem) do rozwiązania problemu odwrotnego w tomografii komputerowej.
- Określenie minimalnego rozmiaru zbioru uczącego potrzebnego do osiągnięcia dobrych wyników.
- Sprawdzenie, czy możliwe jest nauczanie transformacji odwrotnej przy użyciu naturalnych obrazów (nie tomograficznych).
- Opcjonalnie, porównanie wyników z klasycznymi metodami rekonstrukcji.

- Generacja syntetycznego zbioru uczącego.
- Zastosowanie uczenia maszynowego (z nadzorem) do rozwiązania problemu odwrotnego w tomografii komputerowej.
- Określenie minimalnego rozmiaru zbioru uczącego potrzebnego do osiągnięcia dobrych wyników.
- Sprawdzenie, czy możliwe jest nauczanie transformacji odwrotnej przy użyciu naturalnych obrazów (nie tomograficznych).
- Opcjonalnie, porównanie wyników z klasycznymi metodami rekonstrukcji.

- Generacja syntetycznego zbioru uczącego.
- Zastosowanie uczenia maszynowego (z nadzorem) do rozwiązania problemu odwrotnego w tomografii komputerowej.
- Określenie minimalnego rozmiaru zbioru uczącego potrzebnego do osiągnięcia dobrych wyników.
- Sprawdzenie, czy możliwe jest nauczanie transformacji odwrotnej przy użyciu naturalnych obrazów (nie tomograficznych).
- Opcjonalnie, porównanie wyników z klasycznymi metodami rekonstrukcji.

Projekcje tomograficzne

- Każda projekcja to zbiór pomiarów osłabienia promieniowania X pod określonym kątem z określonego miejsca.
- Wzór osłabienia wiązki promieniowania X :

$$I = I_0 e^{-\int \mu(x,y) ds}$$

gdzie:


- I_0 - natężenie promieniowania padającego,
- I - natężenie promieniowania po przejściu przez obiekt,
- $\mu(x,y)$ - współczynnik osłabienia promieniowania w punkcie (x,y) ,
- ds - element drogi przebiegu promieniowania.

Po przekształceniu logarytmicznym:


$$\ln \left(\frac{I_0}{I} \right) = \int \mu(x,y) ds$$

Projekcje tomograficzne

- Projekcje tworzą tzw. **sinogram**.



Rysunek: Wiązka równoległa [1]



Rysunek: Sinogram punktu

- Pary sinogram - obraz przekroju.
- Stosunkowo łatwy dostęp do przekrojów, sinogramy zostaną wygenerowane z użyciem **ASTRA Toolbox** - scenariusz zbioru na podstawie obrazów tomograficznych.
- Zakładamy rekonstrukcję obrazów o rozmiarze 256×256 pikseli.
- Zakładamy sinogramy złożone z projekcji pod 500 kątami, każda projekcja składa się z 256 pomiarów.
- Będzie potrzebne prawdopodobnie kilkaset tysięcy przykładów w zbiorze uczącym.
- Problem wymiarowo duży.

- Pary sinogram - obraz przekroju.
- Stosunkowo łatwy dostęp do przekrojów, sinogramy zostaną wygenerowane z użyciem **ASTRA Toolbox** - scenariusz zbioru na podstawie obrazów tomograficznych.
- Zakładamy rekonstrukcję obrazów o rozmiarze 256×256 pikseli.
- Zakładamy sinogramy złożone z projekcji pod 500 kątami, każda projekcja składa się z 256 pomiarów.
- Będzie potrzebne prawdopodobnie kilkaset tysięcy przykładów w zbiorze uczącym.
- Problem wymiarowo duży.

- Pary sinogram - obraz przekroju.
- Stosunkowo łatwy dostęp do przekrojów, sinogramy zostaną wygenerowane z użyciem **ASTRA Toolbox** - scenariusz zbioru na podstawie obrazów tomograficznych.
- Zakładamy rekonstrukcję obrazów o rozmiarze 256×256 pikseli.
- Zakładamy sinogramy złożone z projekcji pod 500 kątami, każda projekcja składa się z 256 pomiarów.
- Będzie potrzebne prawdopodobnie kilkaset tysięcy przykładów w zbiorze uczącym.
- Problem wymiarowo duży.

- Pary sinogram - obraz przekroju.
- Stosunkowo łatwy dostęp do przekrojów, sinogramy zostaną wygenerowane z użyciem **ASTRA Toolbox** - scenariusz zbioru na podstawie obrazów tomograficznych.
- Zakładamy rekonstrukcję obrazów o rozmiarze 256×256 pikseli.
- Zakładamy sinogramy złożone z projekcji pod 500 kątami, każda projekcja składa się z 256 pomiarów.
- Będzie potrzebne prawdopodobnie kilkaset tysięcy przykładów w zbiorze uczącym.
- Problem wymiarowo duży.

- Pary sinogram - obraz przekroju.
- Stosunkowo łatwy dostęp do przekrojów, sinogramy zostaną wygenerowane z użyciem **ASTRA Toolbox** - scenariusz zbioru na podstawie obrazów tomograficznych.
- Zakładamy rekonstrukcję obrazów o rozmiarze 256×256 pikseli.
- Zakładamy sinogramy złożone z projekcji pod 500 kątami, każda projekcja składa się z 256 pomiarów.
- Będzie potrzebne prawdopodobnie kilkaset tysięcy przykładów w zbiorze uczącym.
- Problem wymiarowo duży.


- Pary sinogram - obraz przekroju.
- Stosunkowo łatwy dostęp do przekrojów, sinogramy zostaną wygenerowane z użyciem **ASTRA Toolbox** - scenariusz zbioru na podstawie obrazów tomograficznych.
- Zakładamy rekonstrukcję obrazów o rozmiarze 256×256 pikseli.
- Zakładamy sinogramy złożone z projekcji pod 500 kątami, każda projekcja składa się z 256 pomiarów.
- Będzie potrzebne prawdopodobnie kilkaset tysięcy przykładów w zbiorze uczącym.
- Problem wymiarowo duży.

1 Metody analityczne

- Bazują na transformacji odwrotnej Radona.
- Przykład: FBP (Filtered Back Projection - Filtrowana projekcja wsteczna).
- Szybkie ale podatne na artefakty.
- Powszechnie stosowane w praktyce klinicznej.

- Filtrowana projekcja wsteczna (FBP):

$$f(x, y) = \mathcal{B}\left\{\mathcal{F}_R^{-1}\{|R| \mathcal{F}_r\{g(r, \theta)\}\}\right\}$$



Rysunek: Algorytm Projektacji Wstecznej [2]

2 Metody statystyczne

- Zakładają, że dane pomiarowe mają charakter probabilistyczny.
- Maksymalizacja wiarygodności otrzymania danych pomiarowych dla danego obrazu.
- Przykład: ML-EM (Maximum Likelihood - Expectation Maximization).

3 Metody algebraiczne

- Proces obrazowania jako układ równań liniowych:

$$Ax = y$$

gdzie:

- A – macierz systemowa,
- x – wektor nieznanych wartości tłumienia w pikselach obrazu,
- y – wektor danych pomiarowych (sinogram).


Celem jest znalezienie rozwiązania:

$$x = \arg \min_x \|Ax - y\|^2$$

- Stosuje się iteracyjne algorytmy optymalizacyjne.
- Złożona obliczeniowo ale dobrze radzi przy źle uwarunkowanej macierzy A .

4 Uczenie maszynowe


- Wykorzystanie sieci neuronowych głębokich do nauki transformacji odwrotnej.
- Czasochłonny proces treningu.
- Szybka rekonstrukcja po wytrenowaniu.
- Redukcja artefaktów i szumów w porównaniu do klasycznych metod.
- Lepsza jakość rekonstrukcji przy niskich dawkach promieniowania.
- Modelowanie transformacji nieliniowej.



Rysunek: Rekonstrukcja za pomocą uczenia maszynowego

1 Architektura U-Net


- Sieć konwolucyjna z blokami kodera i dekodera oraz połączeniami rezyduальnymi.
- Często stosowana przy zadaniach segmentacji i rekonstrukcji obrazów medycznych.
- Najczęstsza architektura w literaturze naukowej do rekonstrukcji tomograficznej [3].



Rysunek: Architektura U-Net

2 Architektury typu GAN

- Generative Adversarial Networks (GAN) - sieci generatywne z przeciwnikiem.
- Składają się z generatora i dyskryminatora.
- Model warunkowanej sieci GAN do przetwarzania obrazów - Pix2Pix [4].



Rysunek: Obraz wejściowy i wygenerowany przez Pix2Pix

3 Architektury transformerowe

- Eksperymentalne przekształcenie architektury transformera wizyjnego.
- Obraz wejściowy (sinogram) dzielimy na tokeny i podajemy na wejście.
- Sekwencja wygenerowana przez transformer to obraz wyjściowy (rekonstrukcja).
- Nowość rozwiązania zaletą wyboru.

4 Architektury mieszane

- Możliwość połączenia architektur, np. U-Net do podstawowej rekonstrukcji, Pix2Pix do odszumiania.

3 Architektury transformerowe

- Eksperymentalne przekształcenie architektury transformera wizyjnego.
- Obraz wejściowy (sinogram) dzielimy na tokeny i podajemy na wejście.
- Sekwencja wygenerowana przez transformer to obraz wyjściowy (rekonstrukcja).
- Nowość rozwiązania zaletą wyboru.

4 Architektury mieszane

- Możliwość połączenia architektur, np. U-Net do podstawowej rekonstrukcji, Pix2Pix do odszumiania.

- Implementacja sieci neuronowej w **Pythonie** używając biblioteki **PyTorch**.
- Podział zbioru na treningowy, testowy i walidacyjny.
- Funkcja celu zależna od modelu.
- Wybór optymalizatora - np. Adam.
- Problem dużego rozmiaru zbioru uczącego, wejść, wyjść i sieci.

- Implementacja sieci neuronowej w **Pythonie** używając biblioteki **PyTorch**.
- Podział zbioru na treningowy, testowy i walidacyjny.
- Funkcja celu zależna od modelu.
- Wybór optymalizatora - np. Adam.
- Problem dużego rozmiaru zbioru uczącego, wejść, wyjść i sieci.

- Implementacja sieci neuronowej w **Pythonie** używając biblioteki **PyTorch**.
- Podział zbioru na treningowy, testowy i walidacyjny.
- Funkcja celu zależna od modelu.
- Wybór optymalizatora - np. Adam.
- Problem dużego rozmiaru zbioru uczącego, wejść, wyjść i sieci.

- Implementacja sieci neuronowej w **Pythonie** używając biblioteki **PyTorch**.
- Podział zbioru na treningowy, testowy i walidacyjny.
- Funkcja celu zależna od modelu.
- Wybór optymalizatora - np. Adam.
- Problem dużego rozmiaru zbioru uczącego, wejść, wyjść i sieci.

- Implementacja sieci neuronowej w **Pythonie** używając biblioteki **PyTorch**.
- Podział zbioru na treningowy, testowy i walidacyjny.
- Funkcja celu zależna od modelu.
- Wybór optymalizatora - np. Adam.
- Problem dużego rozmiaru zbioru uczącego, wejść, wyjść i sieci.

- Generacja syntetycznego zbioru uczącego na podstawie obrazów naturalnych (np. z ImageNet).
- Porównanie jakości rekonstrukcji z siecią wytrenowaną na obrazach tomograficznych.
- Sprawdzenie, czy sieć może nauczyć się ogólnej transformacji odwrotnej niezależnie od specyfiki obrazów.
- Problem - **adaptacja dziedzinowa** (domain adaptation) - tendencja sieci neuronowych do słabszej generalizacji dla danych z innego rozkładu niż dane uczące.

- ❶ **MSE (Mean Squared Error)** – średni błąd kwadratowy:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2$$

- ❶ **MSE (Mean Squared Error)** – średni błąd kwadratowy:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2$$

- ❷ **SSIM (Structural Similarity Index)** – ocenia podobieństwo strukturalne obrazów,

$$\text{SSIM}(x, \hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}$$

- ❶ **MSE (Mean Squared Error)** – średni błąd kwadratowy:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2$$

- ❷ **SSIM (Structural Similarity Index)** – ocenia podobieństwo strukturalne obrazów,

$$\text{SSIM}(x, \hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}$$

- ❸ **PSNR (Peak Signal-to-Noise Ratio)** – stosunek mocy sygnału do szumu:

$$\text{PSNR} = 10 \log_{10} \left(\frac{L^2}{\text{MSE}} \right)$$

Metryki walidacyjne jakości rekonstrukcji

- ❶ **MSE (Mean Squared Error)** – średni błąd kwadratowy:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2$$

- ❷ **SSIM (Structural Similarity Index)** – ocenia podobieństwo strukturalne obrazów,

$$\text{SSIM}(x, \hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}$$

- ❸ **PSNR (Peak Signal-to-Noise Ratio)** – stosunek mocy sygnału do szumu:

$$\text{PSNR} = 10 \log_{10} \left(\frac{L^2}{\text{MSE}} \right)$$

- ❹ **CC (Correlation Coefficient)** – współczynnik korelacji Pearsona:

$$\text{CC} = \frac{\text{cov}(x, \hat{x})}{\sigma_x \sigma_{\hat{x}}}$$

- Wybór technologii wykonania pracy: Python, ASTRA Toolbox, PyTorch.
- Zapoznanie się z literaturą naukową dotyczącą rekonstrukcji tomograficznej z użyciem sieci neuronowych.
- Znalezienie zbioru danych do wstępnych testów - LoDoPaB-CT [5] o wielkości 40000 przykładów.
- Implementacja i trening sieci U-Net w Pythonie (karta RTX 5090).
- Implementacja i trening modelu Pix2Pix w Pythonie (karta RTX 5090).
- Skrypty do generacji syntetycznego zbioru uczącego z użyciem ASTRA Toolbox.

- Wybór technologii wykonania pracy: Python, ASTRA Toolbox, PyTorch.
- Zapoznanie się z literaturą naukową dotyczącą rekonstrukcji tomograficznej z użyciem sieci neuronowych.
- Znalezienie zbioru danych do wstępnych testów - LoDoPaB-CT [5] o wielkości 40000 przykładów.
- Implementacja i trening sieci U-Net w Pythonie (karta RTX 5090).
- Implementacja i trening modelu Pix2Pix w Pythonie (karta RTX 5090).
- Skrypty do generacji syntetycznego zbioru uczącego z użyciem ASTRA Toolbox.


- Wybór technologii wykonania pracy: Python, ASTRA Toolbox, PyTorch.
- Zapoznanie się z literaturą naukową dotyczącą rekonstrukcji tomograficznej z użyciem sieci neuronowych.
- Znalezienie zbioru danych do wstępnych testów - LoDoPaB-CT [5] o wielkości 40000 przykładów.
- Implementacja i trening sieci U-Net w Pythonie (karta RTX 5090).
- Implementacja i trening modelu Pix2Pix w Pythonie (karta RTX 5090).
- Skrypty do generacji syntetycznego zbioru uczącego z użyciem ASTRA Toolbox.

- Wybór technologii wykonania pracy: Python, ASTRA Toolbox, PyTorch.
- Zapoznanie się z literaturą naukową dotyczącą rekonstrukcji tomograficznej z użyciem sieci neuronowych.
- Znalezienie zbioru danych do wstępnych testów - LoDoPaB-CT [5] o wielkości 40000 przykładów.
- Implementacja i trening sieci U-Net w Pythonie (karta RTX 5090).
- Implementacja i trening modelu Pix2Pix w Pythonie (karta RTX 5090).
- Skrypty do generacji syntetycznego zbioru uczącego z użyciem ASTRA Toolbox.

- Wybór technologii wykonania pracy: Python, ASTRA Toolbox, PyTorch.
- Zapoznanie się z literaturą naukową dotyczącą rekonstrukcji tomograficznej z użyciem sieci neuronowych.
- Znalezienie zbioru danych do wstępnych testów - LoDoPaB-CT [5] o wielkości 40000 przykładów.
- Implementacja i trening sieci U-Net w Pythonie (karta RTX 5090).
- Implementacja i trening modelu Pix2Pix w Pythonie (karta RTX 5090).
- Skrypty do generacji syntetycznego zbioru uczącego z użyciem ASTRA Toolbox.


- Wybór technologii wykonania pracy: Python, ASTRA Toolbox, PyTorch.
- Zapoznanie się z literaturą naukową dotyczącą rekonstrukcji tomograficznej z użyciem sieci neuronowych.
- Znalezienie zbioru danych do wstępnych testów - LoDoPaB-CT [5] o wielkości 40000 przykładów.
- Implementacja i trening sieci U-Net w Pythonie (karta RTX 5090).
- Implementacja i trening modelu Pix2Pix w Pythonie (karta RTX 5090).
- Skrypty do generacji syntetycznego zbioru uczącego z użyciem ASTRA Toolbox.

- Uczenie sieci U-Net na zbiorze LoDoPaB-CT:



Rysunek: Błąd treningowy i testowy (MSE) w funkcji epok

- Wyniki rekonstrukcji U-Net na zbiorze LoDoPaB-CT:



Rysunek: Rekonstrukcje 3 obrazów ze zbioru LoDoPaB-CT za pomocą U-Net

- Wybór architektury rozwiązania.
- Generacja syntetycznego zbioru uczącego o odpowiedniej wielkości.
- Trening sieci na syntetycznym zbiorze uczącym, optymalizacja hiperparametrów.
- Ewaluacja jakości rekonstrukcji na zbiorze testowym.
- Analiza wyników, opcjonalnie porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment ze zbiorem uczącym generowanym na podstawie obrazów naturalnych.

- Wybór architektury rozwiązania.
- Generacja syntetycznego zbioru uczącego o odpowiedniej wielkości.
- Trening sieci na syntetycznym zbiorze uczącym, optymalizacja hiperparametrów.
- Ewaluacja jakości rekonstrukcji na zbiorze testowym.
- Analiza wyników, opcjonalnie porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment ze zbiorem uczącym generowanym na podstawie obrazów naturalnych.

- Wybór architektury rozwiązania.
- Generacja syntetycznego zbioru uczącego o odpowiedniej wielkości.
- Trening sieci na syntetycznym zbiorze uczącym, optymalizacja hiperparametrów.
- Ewaluacja jakości rekonstrukcji na zbiorze testowym.
- Analiza wyników, opcjonalnie porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment ze zbiorem uczącym generowanym na podstawie obrazów naturalnych.

- Wybór architektury rozwiązania.
- Generacja syntetycznego zbioru uczącego o odpowiedniej wielkości.
- Trening sieci na syntetycznym zbiorze uczącym, optymalizacja hiperparametrów.
- Ewaluacja jakości rekonstrukcji na zbiorze testowym.
- Analiza wyników, opcjonalnie porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment ze zbiorem uczącym generowanym na podstawie obrazów naturalnych.

- Wybór architektury rozwiązania.
- Generacja syntetycznego zbioru uczącego o odpowiedniej wielkości.
- Trening sieci na syntetycznym zbiorze uczącym, optymalizacja hiperparametrów.
- Ewaluacja jakości rekonstrukcji na zbiorze testowym.
- Analiza wyników, opcjonalnie porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment ze zbiorem uczącym generowanym na podstawie obrazów naturalnych.

- Wybór architektury rozwiązania.
- Generacja syntetycznego zbioru uczącego o odpowiedniej wielkości.
- Trening sieci na syntetycznym zbiorze uczącym, optymalizacja hiperparametrów.
- Ewaluacja jakości rekonstrukcji na zbiorze testowym.
- Analiza wyników, opcjonalnie porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment ze zbiorem uczącym generowanym na podstawie obrazów naturalnych.

- Badanie wpływu rozmiaru zbioru uczącego na jakość rekonstrukcji.
- Porównanie z klasycznymi metodami rekonstrukcji.
- Eksperyment z naturalnymi obrazami.

Dziękuję za uwagę!

- 1 Leuschner J, Schmidt M, Baguer DO, Maass P. LoDoPaB-CT, a benchmark dataset for low-dose computed tomography reconstruction. (2021).
- 2 Qiu, Dejian and Seeram, Euclid. Does Iterative Reconstruction Improve Image Quality and Reduce Dose in Computed Tomography? (2016).
- 3 Koetzier, Lennart et. al. (2023). Deep Learning Image Reconstruction for CT: Technical Principles and Clinical Prospects.
- 4 Isola, Phillip et. al. (2017). Image-to-Image Translation with Conditional Adversarial Networks.
- 5 Leuschner, J., Schmidt, M., Baguer, D.O. et al. LoDoPaB-CT, a benchmark dataset for low-dose computed tomography reconstruction. (2021).