

Pracownia dyplomowa 1

Sprawozdanie z prac nad pracą inżynierską

Rekonstrukcja obrazów tomografii komputerowej za pomocą sieci neuronowej głębokiej na podstawie syntetycznego zbioru uczącego

**Wydział Elektroniki i Technik Informacyjnych
Politechnika Warszawska**

Instytut Automatyki i Informatyki Stosowanej

Semestr 25L

Autor: Kamil Cisek

Kierunek studiów: Automatyka i Robotyka, studia I stopnia

Promotor: prof. dr hab. inż. Waldemar Smolik, Instytut Radioelektroniki i
Technik Multimedialnych

Warszawa, 11.06.2025

1. Plan pracy

Generacja syntetycznego zbioru danych tomograficznych do uczenia z nadzorem. Wybór losowych obrazów (nie związanych z badaniami medycznymi). Transformacja prosta (Radona) obrazów na projekcje tomograficzne (sinogramy). Zakładamy wiązkę równoległą promieniowania X. Uczenie wybranej sieci głębokiej (np. U-Net) transformacji odwrotnej z wykorzystaniem standardowych metryk jakości obrazów. Optymalizacja wyników na zbiorze testowym – dobór hiper parametrów. Walidacja na danych syntetycznych. Walidacja na przekrojach tomograficznych z badań medycznych (format DICOM). Walidacja wymaga przygotowania syntetycznych projekcji (sinogramu).

2. Sieć neuronowa do rekonstrukcji CT - przegląd

Zadaniem opracowywanego modelu uczenia maszynowego będzie generacja obrazu tomograficznego na podstawie projekcji tomograficznej (sinogramu).

W literaturze naukowej opisano wiele prac, w których wykorzystuje się sieci neuronowe do rekonstrukcji obrazów tomografii komputerowej – od podstaw teoretycznych po praktyczne zastosowania. Już w 2016 roku Jin i współpracownicy zaproponowali model FBPCNN, który łączy klasyczną metodę rekonstrukcji FBP z siecią konwolucyjną poprawiającą jakość obrazu [1]. Nowszy artykuł przeglądowy Koetzier i in. (2023) opisuje aktualny stan wiedzy w tej dziedzinie, zwracając uwagę na możliwość zmniejszenia dawki promieniowania przy użyciu głębokiego uczenia [2]. Willemink i Noël (2019) przedstawiają historię rozwoju metod rekonstrukcji – od prostych filtrów po nowoczesne metody oparte na sztucznej inteligencji [3]. Wśród najnowszych podejść, model SD2I (Dong i in., 2022) rekonstruuje obrazy bezpośrednio z sinogramów bez nadzoru [4], a ADAPTIVE-NET i iCT-Net (2020) wykorzystują architektury uwzględniające fizykę przekształcenia Radona [5, 6]. Z kolei DUG-RECON (2020) stosuje sieć U-Net w układzie kaskadowym, aby poprawić jakość i zgodność rekonstrukcji z danymi wejściowymi [7].

Przy pisaniu modelu architektury te będą służyły za punkty wyjścia do eksperymentów. Największym problemem w praktycznym wykonaniu sieci będzie jej duża wymiarowość. Sieć będzie miała bardzo dużo wejść a także bardzo dużo wyjść. Rozmiarem wyjścia - rozdzielczością obrazu tomograficznego, będzie można manipulować. Docelową rozdzielczością będzie prawdopodobnie 512x512, jednak możliwe, że konieczne będzie jej zmniejszenie.

Duży rozmiar sieci będzie powodował problemy zarówno spowodowane długością nauki, jak i tym, że nauczanie takiej sieci wymaga dużego zbioru treningowego.

3. Generacja syntetycznego zbioru uczącego - przegląd

Dostęp do odpowiedniej ilości rzeczywistych danych tomograficznych do wytrenowania modelu będącego przedmiotem pracy będzie niemożliwy. Dlatego ważnym zadaniem w pracy będzie wygenerowanie zbioru uczącego. Z powodu charakteru zadania (dużo wejść i dużo wyjść, duża sieć neuronowa) prawdopodobnie będzie potrzebny zbiór uczący znacznych rozmiarów.

Wybór odpowiedniego oprogramowania zostanie oparty na kompromisie pomiędzy:

- realizmem fizycznym,
- szybkością generacji sinogramu,
- łatwością zastosowania.

Znaleziono kilka potencjalnych narzędzi, które pozwalają generować syntetyczne projekcje tomograficzne:

- **ASTRA** to toolbox dostępny zarówno w Pythonie i w Matlabie. To jedno z najpopularniejszych narzędzi, oferujące szybkie rekonstrukcje z użyciem GPU (CUDA) i intuicyjny interfejs w Pythonie i Matlabie. Choć nie modeluje szczegółowo fizyki (np. rozpraszania czy właściwości materiałów), oferuje bogaty zestaw geometrii (wiązki równoległe, wachlarzowe, stożkowe) i algorytmów (FBP, SART, SIRT itp.) [8].
- **CTL** (Computed Tomography Library) ma duże możliwości konfiguracyjne i umożliwia zastosowanie zaawansowanych modeli detektorów i wiązek [9]. Podstawowa wersja do użycia w C++, istnieje binding do Pythona. Jest jednak trudna w użyciu, ma słabą jakość dokumentacji a także nie jest zbyt popularna.
- **GATE** bazuje na metodach Monte Carlo i umożliwia bardzo realistyczne modelowanie procesu obrazowania, uwzględniając zjawiska losowe i własności materiałów, dzięki temu jest to oprogramowanie często używane przez naukowców. Jej użycie i instalacja jest jednak złożona, wymaga podawania specyficznych plików konfiguracyjnych (które mogą dokładnie opisać modelowany układ, jednak niekoniecznie chcemy aż takiego realizmu, skoro będziemy generować sinogramy na podstawie obrazów). Z powodu realizmu długi jest też czas generowania pojedynczego sinogramu [10].
- **TIGRE** (Tomographic Iterative GPU-based Reconstruction Toolbox) to bardzo popularne oprogramowanie służące głównie do rekonstrukcji 3D, szczególnie do rekonstrukcji tomografii stożkowej. Jest to zaawansowane narzędzie do rekonstrukcji 3D, wspierające użycie GPU [11]. Możliwa jest obsługa obrazów 2D, jednak jest to mało intuicyjne i wymaga dodatkowego dostosowania geometrii 3D do przypadku 2D. Jako, że projekcje 2D nie są głównym zastosowaniem tego oprogramowania nie zawiera ono skomplikowanych funkcji dla tego zagadnienia.

- **ODL** (Operator Discretization Library) zapewnia elastyczność w eksperymentach matematycznych oraz łatwą integrację z PyTorch, ale jego dokumentacja i wydajność pozostawiają nieco do życzenia [12]. Funkcjonalność podobna jak w przypadku ASTRA, jednak wydaje się gorsza i mniej popularna.

Podsumowanie powyższych rozważań przedstawiono w tabeli poniżej (tabela nr 1).

Nazwa	Język	Zalety	Wady	Popularność (★ Github) (stan 8.06.25)
ASTRA	Python, Matlab	- Obsługa CUDA, - Duża popularność, - Dobra dokumentacja, - Stosunkowo łatwa w użyciu - Geometrie wiązki	- Średnio zaawansowana fizyka - Brak właściwości materiałów	513
CTL	C++, Python	- Zaawansowane modele fizyczne - Duże możliwości konfiguracji - Złożone modele detektora	- Niezbyt popularna - Trudniejsza w użyciu - Słaba dokumentacja - Nie najszybsza	-
GATE	C++	- Dobre modelowanie fizyki (model Monte Carlo) - Uwzględnia losową naturę promieniowania - Często używana do celów naukowych - Dobra dokumentacja	- Długi czas obliczeń - Złożona instalacja - Złożone użycie (specyficzne pliki konfiguracyjne)	247
TIGRE	Matlab, Python	- Użycie GPU, szybka - Duża popularność	- Nie do końca dopasowana do zadania (zoptymalizowana do projekcji 3D) - Brak zaawansowanej fizyki - Nie wspiera Pythona 3.12	660
ODL	Python	- Łatwa integracja z pytorch - Duża możliwość przeprowadzania eksperymentalnych	- Niezbyt dobra dokumentacja - Mniej wydajna obliczeniowo	401


		transformacji - Możliwa integracja z ASTRA		
--	--	--	--	--

Tabela nr 1

Po analizie wydaje się, że najlepszym narzędziem do zastosowania w niniejszej pracy jest ASTRA Toolbox. Przede wszystkim, posiada podstawowe wymagane cechy w kontekście fizyki - możliwość wyboru geometrii wiązek. Przez to, że fizyka nie jest jednak bardzo skomplikowana, a biblioteka ma możliwość użycia GPU generacja sinogramów powinna być stosunkowo szybka. Interfejs Pythonowy ASTRA jest bardzo intuicyjny, a dokumentacja jest niezła.

Główną przewagą ASTRA nad GATE czy CTL jest szybkość i łatwość użycia, a dodatkowa fizyka, którą wprowadzają te biblioteki niekoniecznie jest warta wykorzystania, szczególnie, że zadaniem jest generacja sinogramów z obrazów 2D, co ogranicza np. użycie możliwości symulacji materiałów.

ASTRA wygrywa z TIGRE głównie lepszym przystosowaniem do rekonstrukcji obrazów tomograficznych 2D.



Rysunek nr 1

Na rysunku nr 1 przedstawiono przykładowy sinogram wygenerowany biblioteką ASTRA w Pythonie. Obraz wejściowy ma rozmiar 512x512. Zastosowano wiązkę równoległą, 512 kątów projekcji. Wyjściowy sinogram na rozmiar 512x512.

Bibliografia

1. Jin, K. H., McCann, M. T., Froustey, E., & Unser, M. (2016). Deep Convolutional Neural Network for Inverse Problems in Imaging. *arXiv:1611.03679*
2. Jin, K. H., McCann, M. T., Froustey, E., & Unser, M. (2016). Deep Convolutional Neural Network for Inverse Problems in Imaging. *arXiv:1611.03679*
3. Willemink, M. J., & Noël, P. B. (2019). The evolution of image reconstruction for CT—from filtered back projection to artificial intelligence. *European Radiology*, 29(5), 2185–2195.
4. Dong, X., Wu, X., Zhang, S., et al. (2022). SD2I: Sinogram Domain to Image domain translation using Generative Networks without supervision. *Medical Image Analysis*, 77, 102362.
5. Ge, Y., Yu, H., Li, T., & Shi, L. (2020). ADAPTIVE-NET: A Physically Inspired Deep Neural Network for Sparse-View CT Image Reconstruction. *IEEE Transactions on Medical Imaging*, 39(12), 3814–3824.
6. Montoya, J. A., & Chen, H. (2020). iCT-Net: Interpretable and Physics-Informed Neural Network for Sparse-View CT Reconstruction. *arXiv:2008.05442*
7. Kandarpa, K., et al. (2020). DUG-RECON: Deep Unfolded and Guided Reconstruction of CT Images. *Medical Imaging with Deep Learning (MIDL)*.
8. ASTRA Toolbox, *Dokumentacja online*. Dostęp: <https://www.astra-toolbox.com/>, [dostęp: 8.06.2025].
9. Müller, T., & Maier, A. (2021). CTL: A modular open-source C++ library for CT simulations. *Medical Physics*, 48(3), 1224–1236. <https://doi.org/10.1002/mp.14680>
10. Sarrut, D., Buvat, I., Ménard, L., et al. (2021). Advanced Monte Carlo simulations of emission tomography imaging systems with GATE. *Physics in Medicine & Biology*, 66(12), 125012. <https://doi.org/10.1088/1361-6560/ac03d0>
11. Biguri, A., Dos Santos, R., Soleimani, M., & Beard, P. (2025). TIGRE v3: Efficient and easy to use iterative computed tomographic reconstruction toolbox for real datasets. *Engineering Research Express*, 7(1), 015011. <https://doi.org/10.1088/2631-8695/ad2f8e>
12. ODL, *Dokumentacja online*. Dostęp: <https://odlgroup.github.io/odl/>, [dostęp: 8.06.2025].